

MENTOR SABER PRO / ICFES

Asistente Inteligente con RAG y Multiagentes

Informe Técnico — Proyecto Final

Campo	Detalle
Integrante 1	Juan José Bedoya Ramos
Integrante 2	Juan José Ospina Ospina
Asignatura	Introducción a la Inteligencia Artificial
Semestre	2026-I
Repositorio	https://github.com/juan-jose-ospina/mentor-saber-pro.git
Fecha de entrega	Junio 2026

1. Introducción y dominio elegido

Este proyecto desarrolla un asistente inteligente especializado en la preparación de estudiantes para las Pruebas de Estado colombianas (Saber Pro e ICFES). El sistema integra técnicas avanzadas de inteligencia artificial para proporcionar una experiencia de aprendizaje personalizada y adaptativa.

El dominio elegido responde a una necesidad concreta: miles de estudiantes colombianos se preparan anualmente para estas pruebas con recursos fragmentados y sin retroalimentación inmediata. El sistema aborda esta brecha integrando un corpus de preguntas liberadas oficiales del ICFES con un pipeline RAG y dos agentes especializados.

1.1 Módulos cubiertos

- **Lectura crítica:** comprensión de textos y análisis argumentativo.
- **Razonamiento cuantitativo:** matemáticas y estadística básica.
- **Competencias ciudadanas:** constitución y pensamiento social.
- **Comunicación escrita:** redacción y coherencia textual.

1.2 Alcance del sistema

El sistema permite al usuario hacer preguntas en lenguaje natural, recibir explicaciones teóricas fundamentadas en el corpus oficial, practicar con simulacros de preguntas reales, y obtener un

reporte de desempeño exportable en PDF con sus áreas de mejora identificadas.

2. Arquitectura implementada

La arquitectura sigue un patrón de multiagentes orquestados por LangGraph, con un pipeline RAG subyacente que provee contexto fundamentado en fuentes oficiales. El sistema se compone de cinco capas principales:

Capa	Componente	Tecnología
Presentación	Interfaz de usuario	Streamlit
Orquestación	Grafo de agentes	LangGraph
Agentes	Profesor + Evaluador	Python 3.11
Recuperación	Pipeline RAG con re-ranking	ChromaDB + nomic-embed
Generación	LLM Principal	Google AI Studio (Gemini 3.5 Flash)
Skills	Reporte de desempeño	ReportLab (PDF)






Diagrama de Flujo RAG (Retrieval-Augmented Generation)



El flujo de una consulta típica es:

1. El usuario ingresa una pregunta en la interfaz Streamlit.
2. El orquestador LangGraph clasifica la intención (aprender vs. evaluar).
3. Activa el agente correspondiente.
4. El agente ejecuta el pipeline RAG para recuperar contexto relevante.
5. El LLM (Gemini 3.5 Flash) genera una respuesta fundamentada con citación de fuentes.
6. El estado del grafo actualiza el historial del estudiante.

3. Conceptos aplicados

3.1 Arquitectura Transformer

Se utiliza **Gemini 3.5 Flash** (disponible vía Google AI Studio de forma gratuita) como modelo de lenguaje principal. Este modelo se basa en la arquitectura Transformer, que procesa el texto mediante mecanismos de atención para capturar dependencias semánticas de largo alcance.

En el contexto del proyecto, el Transformer recibe como entrada el contexto recuperado por RAG concatenado con la pregunta del usuario, generando una respuesta coherente, pedagógica y fundamentada. Su amplia ventana de contexto es esencial para integrar múltiples fragmentos del corpus en una sola interacción.

3.2 Embeddings

Se utiliza el modelo nomic-embed-text-v1.5 de Nomic AI, disponible de forma gratuita y local mediante la librería sentence-transformers. Este modelo transforma fragmentos de texto en vectores densos de 768 dimensiones que capturan la semántica del contenido. La elección se justifica por su rendimiento superior en textos académicos en español y su capacidad de ejecutarse localmente sin costos de API.

3.3 Base de datos vectorial

ChromaDB se seleccionó como base vectorial por ser completamente open source, de instalación local sin servidor externo (modo embedded), y por ofrecer búsqueda por similitud coseno con filtros de metadatos. Los vectores se indexan con metadatos que incluyen módulo temático, año del examen y tipo de pregunta.

3.4 Pipeline RAG

El pipeline implementa las siguientes etapas:

1. **Ingesta:** lectura de PDFs / documentos con PyMuPDF y extracción de texto estructurado.
2. **Chunking semántico:** fragmentación en ventanas de 512 tokens con overlap de 64 tokens usando LangChain.
3. **Embedding e indexación** en ChromaDB.
4. **Recuperación:** top-5 fragmentos por similitud coseno.
5. **Re-ranking:** uso de un cross-encoder (ms-marco-MiniLM-L-6-v2) para reordenar por relevancia real, mejorando la precisión en un ~15%.
6. **Generación:** prompt estructurado que obliga al LLM a citar fuentes.

3.5 Sistema multiagente

Se implementan dos agentes diferenciados con LangGraph:

- **Agente Profesor:** recibe consultas de tipo explicativo. Ejecuta el pipeline RAG, construye un prompt pedagógico con los fragmentos recuperados y genera una explicación

estructurada (definición, ejemplo, aplicación en el examen).

- **Agente Evaluador:** gestiona los simulacros. Selecciona preguntas del corpus, presenta las opciones, evalúa la respuesta del usuario, proporciona retroalimentación y actualiza el registro de desempeño en el estado del grafo.

El orquestador usa un clasificador de intención liviano para enrutar cada mensaje al agente correcto.

3.6 MCP (Model Context Protocol)

Se integra el servidor MCP de archivos del sistema (*filesystem MCP server*) para que los agentes puedan leer nuevos documentos PDF colocados en la carpeta data/ sin necesidad de reiniciar el servidor. Esto hace el sistema extensible ante nuevas publicaciones del ICFES.

3.7 Skills

Se implementó la Skill '**Exportar reporte de desempeño**', que el Agente Evaluador puede invocar. La skill lee el estado del grafo, genera un reporte PDF estructurado con ReportLab que incluye: resumen de desempeño, identificación de áreas débiles, y recomendaciones de temas prioritarios. El archivo se descarga desde Streamlit.

4. Decisiones técnicas relevantes

Decisión 1: Google AI Studio (Gemini 3.5 Flash) como proveedor LLM

- **Contexto:** Se necesita un LLM potente, rápido, con excelente manejo del español académico y un Tier gratuito robusto para el desarrollo y la sustentación.
- **Decisión:** Integración de Gemini 3.5 Flash mediante la librería oficial google-genai.
- **Consecuencias:** Acceso a una cuota gratuita de hasta 15 peticiones por minuto (RPM) y 1,500 consultas al día. Mitiga costos de infraestructura y ofrece baja latencia en ejecuciones en tiempo real, junto con una ventana de contexto masiva.

Decisión 2: Re-ranking sobre RAG básico

- **Contexto:** La recuperación por similitud vectorial puede retornar fragmentos semánticamente similares pero no directamente relevantes.
- **Decisión:** Añadir cross-encoder ms-marco-MiniLM como re-ranker después de recuperar el top-10, seleccionando los top-5 finales.
- **Consecuencias:** Mejora de precisión ~15% en tests manuales. Latencia adicional de apenas ~200ms. Modelo ligero (22MB) que se ejecuta localmente.

Decisión 3: LangGraph sobre CrewAI

- **Contexto:** Se analizaron frameworks de orquestación para la coordinación multiagente.
- **Decisión:** LangGraph por su modelo de estado explícito, que permite persistir el historial del estudiante en la sesión.
- **Consecuencias:** Mayor control del flujo de la conversación pedagógica. Curva de aprendizaje técnica más alta, pero facilita la Skill de reportes al tener el estado

centralizado.


5. Resultados y limitaciones



5.1 Resultados obtenidos

El sistema responde consultas sobre contenidos ICFES con precisión en menos de 2 segundos en promedio. El Agente Evaluador logra presentar simulacros completos con retroalimentación.

Métrica	Valor obtenido
Documentos en corpus	18 PDFs (preguntas liberadas 2018–2023)
Fragmentos indexados	~2.400 chunks
Tiempo de respuesta promedio	1.8 segundos
Precisión RAG (evaluación manual)	~78% de respuestas relevantes
Módulos cubiertos	4 módulos base

Imágenes de resultados





Deploy

quiero aprender sobre inglés

¡Hola! Qué alegría saludarte. Como tu **Agente Profesor del sistema Mentor Saber Pro**, estoy aquí para guiarte y asegurarme de que domines la estructura de la prueba de Inglés.

A continuación, te presento todo lo que necesitas saber sobre este módulo:

1. Definición

La prueba de **Inglés** es un módulo de competencias genéricas evaluado en las pruebas de Estado (como Saber 11.º y Saber Pro). Su objetivo es evaluar tus habilidades comunicativas en la **lectura y el uso de la lengua inglesa** (gramática y vocabulario en un contexto comunicativo). Esta prueba se alinea con el **Marco Común Europeo de Referencia para las Lenguas (MCER)**, el cual clasifica el desempeño de los estudiantes en niveles que van desde el Pre A1 (incorporado en la actualización de 2020) hasta niveles más avanzados como A1, A2, B1, B2, C1 y C2. La prueba se compone de un total de **siete partes**, cada una diseñada para evaluar una habilidad específica.

2. Ejemplo práctico

Un ejemplo muy común de cómo se evalúa esta competencia es la **Parte 1 (Relacionar)** de la prueba:

- **Dinámica:** Se te presenta una columna a la izquierda con 5 descripciones cortas (numeradas del 1 al 5) y una columna a la derecha con opciones de palabras (de la A a la G).
- **Tu tarea:** Debes asociar cada descripción con la palabra correcta.
- **Condiciones:** La opción H siempre se usa como el ejemplo ilustrativo del inicio, lo que significa que te quedarán las demás opciones para responder y, al final, **te sobrarán dos opciones** que actúan como distractores.

3. Tip para el examen

El truco del **"Descarte Activo"** en la **Parte 1:** Antes de leer las descripciones de la izquierda, dale una mirada rápida a la lista de palabras de la derecha para activar tu vocabulario en inglés. A medida que vayas emparejando las descripciones con su palabra correspondiente, **tacha físicamente en tu cuadernillo** las opciones que ya utilices (incluyendo el ejemplo H). Esto reducirá visualmente tus opciones, evitará que te confundas con los distractores y te ayudará a responder más rápido por descartar en las preguntas que te generen dudas.

4. Fuente consultada

- [cuadernillo_ingles_2024.pdf](#)
- [explicacion_ingles.pdf](#)

Escribe tu pregunta o pide un simulacro...

Deploy

sigamos con otra pregunta pero sí de inglés

¡Entendido! Vamos a pasar de la teoría a la práctica. A continuación, te presento una pregunta de la **Parte 6 (Comprensión Lectora)** de la prueba de Inglés de Saber 11.º.

En esta parte, debes leer un texto corto y responder una pregunta de comprensión inferencial o de detalle, eligiendo entre cuatro opciones (A, B, C o D).

Reading Comprehension

Read the text and answer the question:

The Cost of Fast Fashion The environmental impact of the fashion industry has become a major global concern. Every year, millions of tons of clothes are produced, and a large percentage ends up in landfills. Synthetic fibers like polyester are cheap and popular, but they take hundreds of years to biodegrade, polluting oceans with microplastics. While some brands are now trying to use organic cotton and recycled materials, environmentalists argue that the real solution is not just green manufacturing, but for consumers to buy less and wear their clothes for longer.

Question: According to the text, what do environmentalists believe is the most effective solution to the fast fashion crisis?

A. Replacing all organic cotton with synthetic fibers. B. Reducing consumption and extending the lifespan of clothes. C. Recycling all the clothes that currently end up in landfills. D. Increasing the production of cheap polyester garments.

¿Cuál es tu respuesta?

la c es la correcta

¡Hola! Como tu **Agente Evaluador**, he procesado tu respuesta.

Tu respuesta es **INCORRECTA** ❌.

Justificación:

La opción correcta es la **B: Reducing consumption and extending the lifespan of clothes**.

- **¿Por qué la C es incorrecta?** Aunque el texto menciona que algunas marcas intentan usar materiales reciclados ("recycled materials"), el texto aclara que los ambientalistas argumentan que la verdadera solución no es solo la fabricación ecológica (que incluye el reciclaje), por lo que reciclar toda la ropa no es lo que ellos proponen como la solución más efectiva.

Escribe tu pregunta o pide un simulacro...

Mentor Saber Pro
ASISTENTE ICFES - v2.0

API Key de Google

API Key configurada

Puntaje de la Sesión

1 Correctos

3 Incorrectos

Corpus ICFES

PDFs detectados en total: 18

Ver PDFs detectados

Reporte de Desempeño

hazme un simulacro

¡Excelente! Como tu **Agente Evaluador**, he preparado un simulacro con preguntas tipo ICFES para poner a prueba tus habilidades en la prueba de **Ciencias Naturales** (específicamente en la competencia de *Indagación*).

Comencemos con la primera pregunta:

Pregunta 1:

Un grupo de estudiantes quiere investigar cómo influye la intensidad de la luz en la tasa de fotosíntesis de una planta acuática llamada Elodea. Para ello, realizan un experimento donde colocan la planta en un recipiente con agua y la ubican a diferentes distancias de una bombilla (10 cm, 20 cm, 30 cm y 40 cm). Para medir la tasa de fotosíntesis, cuentan la cantidad de burbujas de oxígeno que la planta libera por minuto en cada distancia.

Teniendo en cuenta el diseño experimental de los estudiantes, ¿cuál es la variable independiente y cuál es la variable dependiente en esta investigación?

A. La variable independiente es la cantidad de burbujas de oxígeno liberadas y la variable dependiente es la distancia a la bombilla. B. La variable independiente es la distancia a la bombilla y la variable dependiente es la cantidad de burbujas de oxígeno liberadas. C. La variable independiente es el tipo de planta (Elodea) y la variable dependiente es el tiempo de medición (un minuto). D. La variable independiente es la temperatura del agua y la variable dependiente es la intensidad de la luz.

¿Cuál es tu respuesta?

la B

¡Excelente elección! Tu respuesta es **CORRECTA** ✓

Justificación:

En un diseño experimental:

1. La **variable independiente** es aquella que el investigador manipula o cambia deliberadamente para observar sus efectos. En este caso, los estudiantes modifican la **distancia a la bombilla** (10 cm, 20 cm, 30 cm y 40 cm) para variar de forma indirecta la intensidad de la luz.
2. La **variable dependiente** es la que se mide o registra para ver cómo responde a los cambios de la variable independiente. En este experimento, se mide la **cantidad de burbujas de oxígeno liberadas por minuto**, lo cual es un indicador directo de la tasa de fotosíntesis.

- ¿Por qué las otras opciones no son correctas?

Escribe tu pregunta o pide un simulacro...

Mentor Saber Pro – ICFES

Reporte de Desempeño Académico

Generado el: 06/06/2026 01:09

Métrica	Resultado
■ Respuestas Correctas	1
■ Respuestas Incorrectas	3
■ Total de Preguntas	4
■ Porcentaje de Éxito	25.0%

Diagnóstico:

Necesitas reforzar los conceptos fundamentales. Te recomendamos revisar los cuadernillos oficiales del ICFES con el Agente Profesor.

Este reporte fue generado automáticamente por Mentor Saber Pro v2.0. Toda la información proviene del corpus oficial de cuadernillos del ICFES.

5.2 Limitaciones

- El corpus está limitado a preguntas liberadas públicamente; no incluye la totalidad de los

temas del examen real.

- El límite de la API gratuita de Google AI Studio (15 RPM) requiere control de peticiones concurrentes en la demo.
- El sistema no tiene memoria persistente permanente (el estado del grafo se reinicia al cerrar la aplicación de Streamlit).

6. Conclusiones

Este proyecto demostró la viabilidad de construir un asistente educativo especializado usando herramientas gratuitas. La integración de RAG con multiagentes permite separar claramente las responsabilidades pedagógicas (explicar vs. evaluar), mejorando la coherencia. El patrón RAG con re-ranking resulta especialmente valioso en dominios de exámenes estandarizados, donde la recuperación conceptual exacta es crítica. LangGraph demostró ser una herramienta poderosa para mantener el estado conversacional y coordinar agentes.

Trabajo futuro:

1. Implementar memoria persistente entre sesiones (SQLite).
2. Ampliar el corpus con guías de preparación adicionales.
3. Integrar evaluación automática con *LLM-as-judge* para medir de forma continua la calidad de las explicaciones.

Referencias

- ICFES. (2023). Preguntas liberadas Saber Pro. <https://www.icfes.gov.co>
- Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.
- LangChain. (2024). LangGraph documentation. <https://langchain-ai.github.io/langgraph/>
- Nomic AI. (2024). nomic-embed-text-v1.5. <https://huggingface.co/nomic-ai/nomic-embed-text-v1.5>
- Google AI for Developers. (2024). Gemini API documentation. <https://ai.google.dev/gemini-api/docs>
- ChromaDB. (2024). ChromaDB documentation. <https://docs.trychroma.com>